

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE  
SANTA CATARINA - CÂMPUS FLORIANÓPOLIS  
DEPARTAMENTO ACADÊMICO DE ELETRÔNICA  
CURSO SUPERIOR DE ENGENHARIA ELETRÔNICA**

**ANA CLÁUDIA BANDERCHUK**

**TÍTULO DO TCC**

**Florianópolis, 2021**

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE  
SANTA CATARINA - CÂMPUS FLORIANÓPOLIS  
DEPARTAMENTO ACADÊMICO DE ELETRÔNICA  
CURSO SUPERIOR DE ENGENHARIA ELETRÔNICA**

**ANA CLÁUDIA BANDERCHUK**

## **TÍTULO DO TCC**

Trabalho de conclusão de curso submetido  
ao Instituto Federal de Educação, Ciência  
e Tecnologia de Santa Catarina como parte  
dos requisitos para obtenção do título de  
engenheiro eletrônico

Orientador:  
Prof. Dr. Fernando Santana Pacheco

**Florianópolis, 2021**

Ficha de identificação da obra elaborada pelo autor.

Allebrandt, Diesson Stefano  
**Estudo da redução da interferência eletromagnética  
de um conversor estático do tipo Buck interleaved / Diesson  
Stefano Allebrandt ; orientação de Luis Carlos Martinhago  
Schlichting; coorientação de Joabel Moia.**  
- Florianópolis, SC, 2021.  
82 p.  
**Trabalho de Conclusão de Curso (TCC) - Instituto Federal  
de Santa Catarina, Câmpus Florianópolis. Bacharelado  
em Engenharia Eletrônica. Departamento Acadêmico  
de Eletrônica.**  
Inclui Referências.

1. Compatibilidade eletromagnética. 2. Eletrônica  
de potência. 3. Buck interleaved. 4. Conversor Buck com  
célula de comutação de três estados. I. Schlichting,  
Luis Carlos Martinhago . II. Moia, Joabel . III.  
Instituto Federal de Santa Catarina. Departamento Acadêmico  
de Eletrônica. IV. Título.

# **TÍTULO DO TCC**

**ANA CLÁUDIA BANDERCHUK**

Este Trabalho foi julgado adequado para obtenção do Título de Engenheiro Eletrônico em abril de 2021 e aprovado na sua forma final pela banca examinadora do Curso de Engenharia Eletrônica do Instituto Federal de Educação, Ciência, e Tecnologia de Santa Catarina.

Florianópolis, 12 de março, 2021.

Banca Examinadora:

---

Fernando Santana Pacheco, Dr.

## RESUMO

Este trabalho apresenta

**Palavras-chave:** um. dois.

## **ABSTRACT**

This papper presents

**Keywords:**

## LISTA DE ILUSTRAÇÕES

Figura 1 – Diagrama de Venn da Inteligência Artificial e suas áreas de estudo.	10
Figura 2 – Fluxograma que diferencia as áreas de estudo da Inteligência Artificial e suas etapas de processamento de dados. . . . .	11
Figura 3 – Ilustração das camadas de um modelo de Aprendizado Profundo. .	12
Figura 4 – Comparação entre os modelos Aprendizado de Máquina e Aprendizado Profundo. . . . .	12

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO . . . . .</b>	<b>8</b>
<b>1.1</b>	<b>Justificativa . . . . .</b>	<b>8</b>
<b>1.2</b>	<b>Descrição do problema . . . . .</b>	<b>8</b>
<b>1.3</b>	<b>Objetivo geral . . . . .</b>	<b>8</b>
<b>1.4</b>	<b>Objetivos específicos . . . . .</b>	<b>8</b>
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>	<b>9</b>
<b>2.1</b>	<b>Inteligência Artificial . . . . .</b>	<b>9</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>13</b>



## **1 INTRODUÇÃO**

Placas de circuito impresso são de longe o método mais utilizado para o projeto de eletrônicos modernos. Elas consistem em um sanduíche de uma ou mais camadas de cobre intercaladas com uma ou mais camadas de material isolante (ZUM-BAHLEN, 2008) e servem de suporte para os componentes eletrônicos responsáveis pelo funcionamento de um circuito eletrônico.

À medida em novas tecnologias são desenvolvidas, as placas de circuito impresso estão se tornando cada vez mais sofisticadas e delicadas (HU; WANG, 2020), de modo que a detecção de incertezas, tolerâncias, defeitos e erros de posição relativa associados ao processo de fabricação (LETA; FELICIANO; MARTINS, 2008) deve ser feita com mais cautela a fim de garantir o funcionamento do produto final.

Dessa forma, automatizar a inspeção de defeitos se tornou essencial para aprimorar a qualidade do processo de fabricação, já que técnicas de medição por visão computacional apresentam melhor regularidade, precisão e repetibilidade quando comparada a inspeção humana que, além da imprecisão e não-repetibilidade, está sujeita a subjetividade, fadiga e lentidão e está, ainda, associada a um alto custo (LETA; FELICIANO; MARTINS, 2008).

A inspeção ótica automatizada (AOI) vem sendo amplamente utilizada para detectar defeitos durante o processo de fabricação de uma PCB (CHIN; HARLOW, 1982). Conforme a evolução dessa tecnologia, três principais métodos de detecção tem se destacado: métodos comparativos, não-referenciais e híbridos (WU; WANG; LIU, 1996). O método comparativo, mais utilizado entre eles, está susceptível à interferência da iluminação e ruídos externos, além de necessitar mecanismos de alinhamento precisos para realização da comparação (HU; WANG, 2020).

Tanto mentes humanas quanto computadores podem utilizar informações simbólicas para manipulá-las de acordo com um conjunto formal de regras e como resultado, resolver problemas, formar julgamentos e/ou tomar decisões (DICK, 2019).

### **1.1 Justificativa**

### **1.2 Descrição do problema**

### **1.3 Objetivo geral**

### **1.4 Objetivos específicos**

Com o objetivo geral apresentado, destaca-se os seguintes objetivos específicos:

## 2 FUNDAMENTAÇÃO TEÓRICA

Nesse capítulo serão apresentados os principais conceitos necessários para a compreensão desse trabalho.

### 2.1 Inteligência Artificial

Apesar de ter chamado atenção nos últimos anos com a quantidade enorme de dados adquiridos e processados por grandes corporações como Google, Facebook, Amazon, e Apple (RUSSELL; MOSKOWITZ; JALAIAN, 2020), o termo ‘Inteligência Artificial’ não é tão atual assim. Ele foi utilizado pela primeira vez em 1955 por John McCarthy (ABRAHAM et al., 2021), que conduziu no ano seguinte um workshop cuja premissa central da proposta considera que o comportamento humano inteligente consiste em processos que podem ser formalizados e reproduzidos por uma máquina (DICK, 2019).

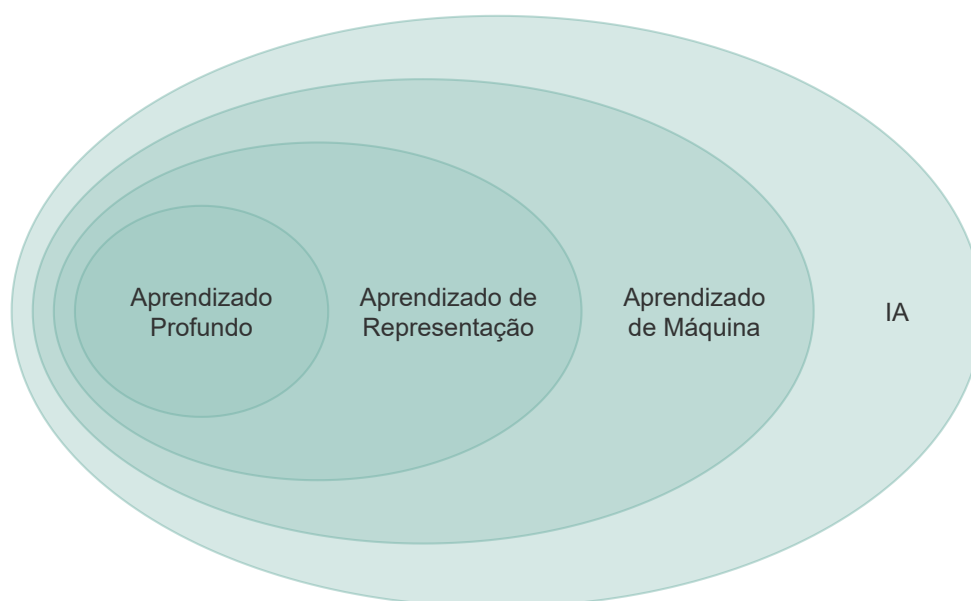
Um dos objetivos da Inteligência Artificial, de acordo com Mitchell, Michalski e Carbonell (2013), é fazer com que computadores realizem tarefas mais inteligentes de forma com que não haja necessidade dos seres humanos executá-las. Entretanto, um dos grandes desafios da área de IA atualmente é a execução de atividades consideradas simples e corriqueiras para pessoas, como reconhecimento de objetos e fala (GOODFELLOW; BENGIO; COURVILLE, 2016).

A Inteligência Artificial engloba a área de estudo do Aprendizado de Máquina, que por sua vez englobam as áreas do Aprendizado de Representação e Aprendizado Profundo, conforme o diagrama de Venn apresentado na Figura 1.

Para evidenciar as diferenças entre essas áreas de estudo, em comparação com simples Sistemas Baseados em Regras, Goodfellow, Bengio e Courville (2016) apresenta um fluxograma com as etapas de processamento entre a entrada e a saída de dados para cada uma delas, presente na Figura 2.

Sistemas Baseados em Regras não possuem componentes capazes de realizar qualquer aprendizado a partir de dados (GOODFELLOW; BENGIO; COURVILLE, 2016) e são utilizados para resolução de problemas e/ou execução de tarefas que podem ser descritos por uma lista de regras formais, como por exemplo jogar Xadrez. Ao contrário desses sistemas, o Aprendizado de Máquina (do inglês *Machine Learning*) utiliza algoritmos computacionais para transformar características reunidas empiricamente por cientistas de dados em modelos utilizáveis (EDGAR; MANZ, 2017) (ROBINS, 2020) possuindo a capacidade “de se aprimorar [...], aprendendo novos conhecimentos ao invés de serem programado com eles” (WOOLF, 2009).

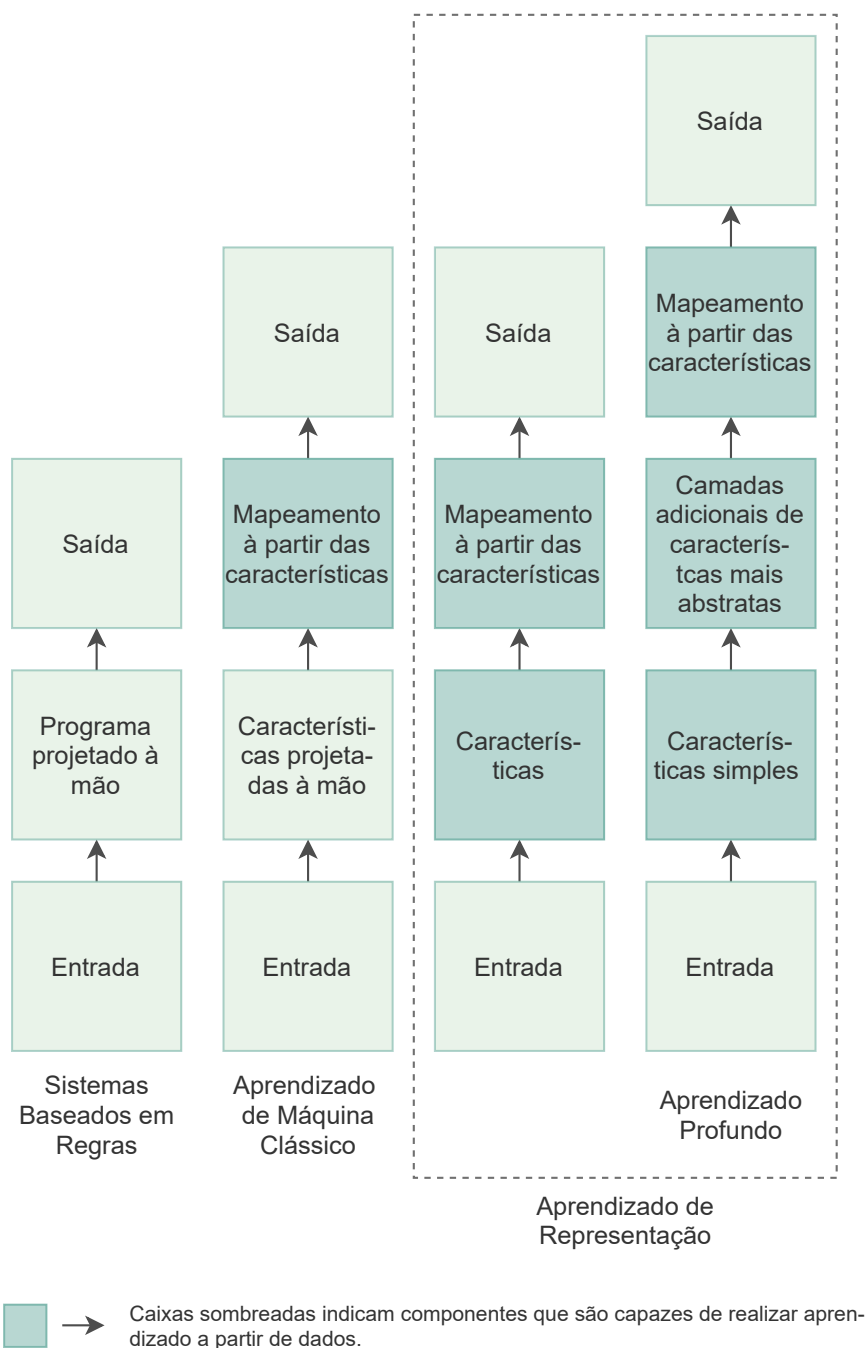
No Aprendizado de Representação (do inglês *Feature Learning* ou *Representation Learning*) entretanto, não há necessidade de mapear manualmente essas

**Figura 1 – Diagrama de Venn da Inteligência Artificial e suas áreas de estudo.**

Fonte: Adaptado de Goodfellow, Bengio e Courville (2016).

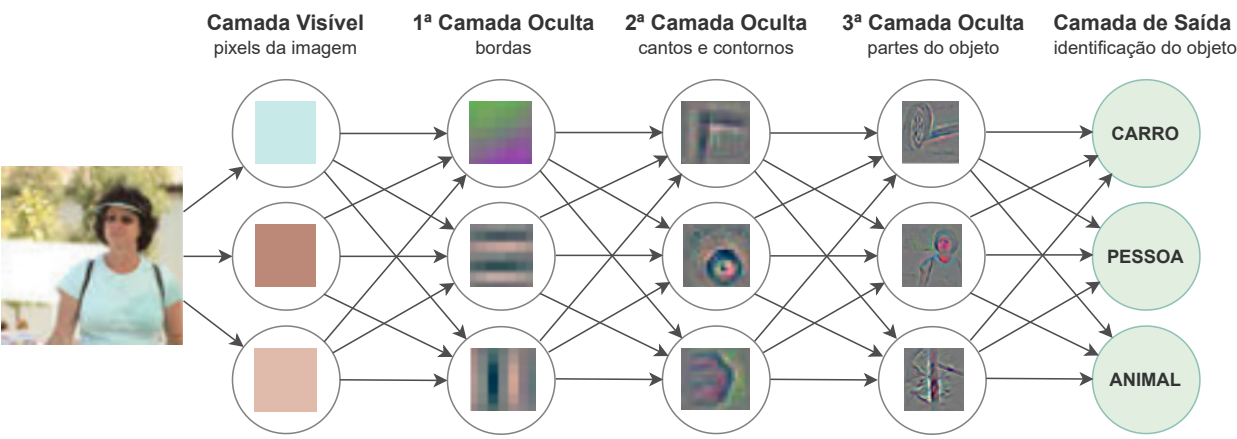
características (GOODFELLOW; BENGIO; COURVILLE, 2016). Ou seja, por conta própria e de forma abstrata, os algoritmos são capazes de extrair as características importantes para a construção dos modelos utilizando redes neurais (ROBINS, 2020) (LESORT et al., 2018). O Aprendizado Profundo, por sua vez, resolve dificuldade que o Aprendizado de Representação possui de extrair características abstratas de alto nível, tais como sotaques de um locutor (GOODFELLOW; BENGIO; COURVILLE, 2016). Segundo Mao et al. (2019), o Aprendizado Profundo “imita a função que o cérebro humano possui de interpretar dados usando redes neurais de várias camadas”. Um exemplo dessas variadas camadas é apresentado na Figura 3 e uma comparação com o modelo de Aprendizado de Máquina é ilustrado na Figura 4.

**Figura 2 – Fluxograma que diferencia as áreas de estudo da Inteligência Artificial e suas etapas de processamento de dados.**



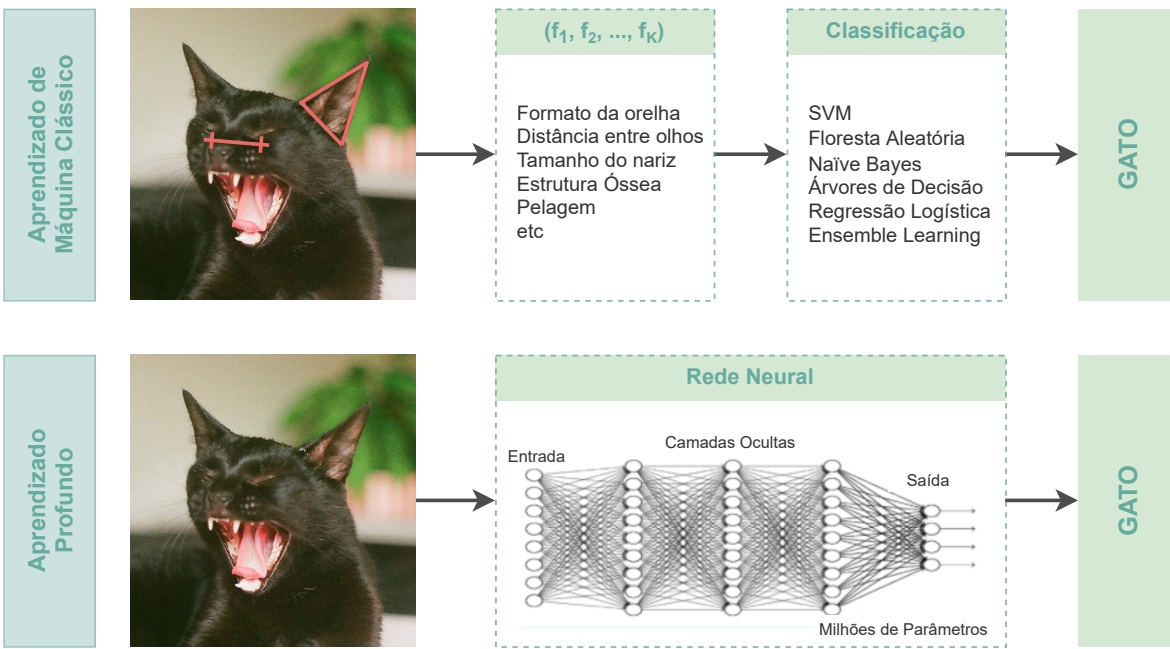
Fonte: Adaptado de Goodfellow, Bengio e Courville (2016).

Figura 3 – Ilustração das camadas de um modelo de Aprendizado Profundo.



Fonte: Adaptado de Goodfellow, Bengio e Courville (2016).

Figura 4 – Comparação entre os modelos Aprendizado de Máquina e Aprendizado Profundo.



Fonte: Adaptado de Robins (2020).

## REFERÊNCIAS

- ABRAHAM, T. et al. Contributors. In: COHEN, S. (Ed.). *Artificial Intelligence and Deep Learning in Pathology*. Elsevier, 2021. p. xiii–xiv. ISBN 978-0-323-67538-3. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780323675383010022>>. Citado na página 9.
- CHIN, R. T.; HARLOW, C. A. Automated visual inspection: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-4, n. 6, p. 557–573, 1982. Citado na página 8.
- DICK, S. Artificial intelligence. *Harvard Data Science Review*, v. 1, n. 1, 7 2019. <https://hdsr.mitpress.mit.edu/pub/0aytgrau>. Disponível em: <<https://hdsr.mitpress.mit.edu/pub/0aytgrau>>. Citado 2 vezes nas páginas 8 e 9.
- EDGAR, T. W.; MANZ, D. O. Chapter 6 - machine learning. In: EDGAR, T. W.; MANZ, D. O. (Ed.). *Research Methods for Cyber Security*. Syngress, 2017. p. 153–173. ISBN 978-0-12-805349-2. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780128053492000066>>. Citado na página 9.
- GOODFELLOW, I. J.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. <<http://www.deeplearningbook.org>>. Citado 4 vezes nas páginas 9, 10, 11 e 12.
- HU, B.; WANG, J. Detection of pcb surface defects with improved faster-rcnn and feature pyramid network. In: . [S.l.: s.n.], 2020. v. 8, p. 108335–108345. Citado na página 8.
- State representation learning for control: An overview. *Neural Networks*, v. 108, p. 379–392, 2018. ISSN 0893-6080. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0893608018302053>>. Citado na página 10.
- LETA, F. R.; FELICIANO, F. F.; MARTINS, F. P. R. Computer vision system for printed circuit board inspection. In: *ABCM Symposium Series in Mechatronics*. [S.l.: s.n.], 2008. v. 3, p. 623 – 632. Citado na página 8.
- MAO, S. et al. Opportunities and challenges of artificial intelligence for green manufacturing in the process industry. *Engineering*, v. 5, n. 6, p. 995–1002, 2019. ISSN 2095-8099. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2095809919300074>>. Citado na página 10.
- MITCHELL, R.; MICHALSKI, J.; CARBONELL, T. *An artificial intelligence approach*. [S.l.]: Springer, 2013. Citado na página 9.
- ROBINS, M. The difference between artificial intelligence, machine learning and deep learning. *Intel Artificial Intelligence*, 5 2020. Disponível em: <<https://www.intel.com.br/content/www/br/pt/artificial-intelligence/posts/difference-between-ai-machine-learning-deep-learning.html>>. Citado 3 vezes nas páginas 9, 10 e 12.
- RUSSELL, S.; MOSKOWITZ, I. S.; JALAIAN, B. Chapter 4 - context: Separating the forest and the trees—wavelet contextual conditioning for ai. In: LAWLESS,

- W. F.; MITTU, R.; SOFGE, D. A. (Ed.). *Human-Machine Shared Contexts*. Academic Press, 2020. p. 67–91. ISBN 978-0-12-820543-3. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780128205433000043>>. Citado na página 9.
- WOOLF, B. P. Chapter 7 - machine learning. In: WOOLF, B. P. (Ed.). *Building Intelligent Interactive Tutors*. San Francisco: Morgan Kaufmann, 2009. p. 221–297. ISBN 978-0-12-373594-2. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780123735942000071>>. Citado na página 9.
- WU, W.-Y.; WANG, M.-J. J.; LIU, C.-M. Automated inspection of printed circuit boards through machine vision. *Computers in Industry*, v. 28, n. 2, p. 103–111, 1996. ISSN 0166-3615. Disponível em: <<https://www.sciencedirect.com/science/article/pii/0166361595000631>>. Citado na página 8.
- ZUMBAHLEN, H. Chapter 12 - printed circuit-board design issues. In: ZUMBAHLEN, H. (Ed.). *Linear Circuit Design Handbook*. Burlington: Newnes, 2008. p. 821–895. ISBN 978-0-7506-8703-4. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780750687034000122>>. Citado na página 8.